

4/3/2022

Προσέγγιση Τιμών Ακινήτων με χρήση Αλγορίθμων Μηχανικής Μάθησης



email: george-baltzakis@hotmail.gr

Εισαγωγή

Η παρούσα εργασία έχει ως στόχο την ανάπτυξη αλγορίθμων μηχανικής μάθησης για την προσέγγιση της διάμεσης τιμής ενός ακινήτου σε μια ευρύτερη γεωγραφική περιοχή της πολιτείας της Καλιφόρνια βάσει ενός συνόλου αντικειμενικών χαρακτηριστικών των ακινήτων στην εν λόγω περιοχή. Κάθε τέτοια περιοχή αποτελεί στην πραγματικότητα την μικρότερη γεωγραφική οντότητα που καταγράφηκε στην σχετική απογραφή του 1990 με πληθυσμιακό εύρος μεταξύ των 600 και 3000 κατοίκων. Το σχετικό σύνολο των δεδομένων είναι αποθηκευμένο στο αρχείο "housing.csv".

Η διαδικασία εκπαίδευσης των εμπλεκόμενων μηχανισμών μηχανικής μάθησης θα πρέπει να βασιστεί σε ένα σύνολο αντικειμενικών γνωρισμάτων των ακινήτων που υπάρχουν σε κάθε γεωγραφική περιοχή το οποίο περιλαμβάνει τα παρακάτω χαρακτηριστικά:

- i. το γεωγραφικό μήκος (longitude) του κέντρου της περιοχής.
- ii. το γεωγραφικό πλάτος (latitude) του κέντρου της περιοχής.
- iii. την διάμεση ηλικία των ακινήτων (housing median age) της περιοχής.
- iv. το συνολικό πλήθος δωματίων (total_rooms) των ακινήτων της περιοχής.
- v. το συνολικό πλήθος υπνοδωματίων (total_bedrooms) των ακινήτων της περιοχής.
- vi. τον πληθυσμό (population) της περιοχής
- vii. το πλήθος των νοικοκυριών (households) της περιοχής
- viii. το διάμεσο εισόδημα (median_income) των κατοίκων της περιοχής
- ix. την εγγύτητα προς τον ωκεανό (ocean_proximity) της περιοχής ώστε να προσεγγιστεί:
 - x. η διάμεση τιμή (median house value) των ακινήτων της περιοχής.

Η υλοποίηση των μηχανισμών μάθησης, η προ επεξεργασία και οπτικοποίηση των δεδομένων, πραγματοποιήθηκε με τη βοήθεια της γλώσσας Προγραμματισμού **Python** και μερικών βιβλιοθηκών της. Πιο συγκεκριμένα, χρησιμοποιήθηκαν:

- Python 3.7.11
- Jupyter 1.0.0
- Pandas 1.3.5
- NumPy 1.21.2
- TensorFlow 2.0.0
- Scikit-Learn 1.0.2
- Matplotlib 3.5.1

- 1. Προ Επεξεργασία Δεδομένων:
 - α. Εισαγωγή Δεδομένων (Ελεγχος για διπλότυπες εγγραφές)

```
1 jimport numpy as np
                            2 import pandas as pd
                            3 from sklearn import preprocessing
                               import matplotlib.pyplot as plt
                            5 from sklearn.model_selection import KFold
                            6 from sklearn.metrics import mean_absolute_error
                            7 from tensorflow.keras.models import Sequential
                            8 from tensorflow.keras.layers import Dense
                            9 from tensorflow.keras.optimizers import Adam
                           10 from tensorflow.keras.callbacks import EarlyStopping
                            1 # Import Data
                            original_data = pd.read_csv('housing.csv')
                            3 data = pd.read_csv('housing.csv')
                            5 # Drop Duplicates
                              data.drop_duplicates()
                            8 # A First View of Data
                            9 print("\n\tData Info\n")
                           10 data.info()
                           print("\n\n\tData Head\n")
                           12 data.head()
  Data Info
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 20640 entries, 0 to 20639
Data columns (total 10 columns):
# Column
                 Non-Null Count Dtype
                 20640 non-null float64
  longitude
   latitude
                  20640 non-null
                              float64
   housing_median_age 20640 non-null
  total_bedrooms 20433 rc-
                              float64
                  20433 non-null float64
                 20640 non-null float64
  households
   median_income
                  20640 non-null float64
   median_house_value 20640 non-null float64
  ocean_proximity
                  20640 non-null object
dtypes: float64(9), object(1)
memory usage: 1.6+ MB
```

 V
 longitude
 latitude
 housing_median_age
 total_rooms
 total_bedrooms
 population
 households
 median_income
 median_house_value
 ocan_proximity

 0
 -122.23
 37.85
 41.0
 888.0
 129.0
 322.0
 126.0
 8.3252
 452600.0
 NEAR BAY

 1
 -122.22
 37.85
 52.0
 1467.0
 190.0
 496.0
 177.0
 7.2574
 352100.0
 NEAR BAY

 3
 -122.25
 37.85
 52.0
 127.0
 235.0
 558.0
 219.0
 5.6431
 34300.0
 NEAR BAY

 4
 -122.25
 37.85
 52.0
 1627.0
 280.0
 565.0
 259.0
 3.8462
 342200.0
 NEAR BAY

- b. Έλεγχος για εγγραφές που περιέχουν κενά πεδία:
 - i. Αντικατάσταση των πεδίων αυτών με τη διάμεση τιμή του συγκεκριμένου χαρακτηριστικού.

c. Εφαρμογή *Min Max* Αλγορίθμου Κλιμάκωσης (scaling) στο διάστημα [0,1], για τα αριθμητικά Δεδομένα.

```
# 2) MinMax Scaling to [0, 1]

2 data_columns_for_scaling = ['housing_median_age', 'total_rooms', 'total_bedrooms',

3 data_columns_for_scaling] = preprocessing.MinMaxScaler().fit_transform(data[data_columns_for_scaling])
```

d. Εφαρμογή One Hot Vector Encoding για το κατηγορικό χαρακτηριστικό.

```
# 3) One Hot Vector Encoding
data.groupby('ocean_proximity')['ocean_proximity'].count()

# We save this Series for Visualization
ocean_proximity = data.ocean_proximity


# Create a One Hot Vector Encoding DataFrame
one_hot_vector_encoding = pd.get_dummies(data.ocean_proximity, prefix = 'Ocean_Proximity')

# Join that to the data DataFrame
data = data.join(one_hot_vector_encoding)


# Delete the column: ocean_proximity
data.drop(['ocean_proximity'], axis = 1, inplace = True)
```

- 2. Οπτικοποίηση Δεδομένων:
 - α. Προβολή Ιστογράμματος για κάθε χαρακτηριστικό.

```
1 🗆#
 2 # -- Data Visualization --
3 -#
1 ⊡# 1) Frequency Histograms of each column
2 #
 3 -# For all numeric columns
 4 □for i in data.columns[:-5]:
5
       plt.figure()
       plt.hist(data[i], bins=50)
7 🗀
       plt.gca().set(title=i, ylabel='Frequency')
9 # For Categorical feature: ocean_proximity
10 plt.figure()
plt.title('ocean_proximity')
12 plt.ylabel('Frequency')
13 ocean_proximity.value_counts().plot(kind='bar')
14 plt.show()
```



b. Προβολή Πολλαπλών Ιστογραμμάτων.



```
# Second between total_rooms, total_bedrooms and median_house_value
plt.figure(figsize=(13, 4))
plt.title('total_rooms, total_bedrooms and median_house_value')


plt.hist(data.total_rooms, bins = 500, alpha = 0.5, label = 'total_rooms')

plt.hist(data.total_bedrooms, bins = 500, alpha = 0.5, label = 'total_bedrooms')

plt.hist(data.median_house_value, bins = 500, alpha = 0.5, label = 'median_house_value')

plt.legend(loc='upper left')

plt.show()
```



```
# And Last between total_rooms, total_bedrooms, median_house_value and median_income
plt.figure(figsize=(13, 4))

plt.title('total_rooms, total_bedrooms, median_house_value and median_income')

plt.hist(data.total_rooms, bins = 500, alpha = 0.5, label = 'total_rooms')


plt.hist(data.total_bedrooms, bins = 500, alpha = 0.5, label = 'total_bedrooms')

plt.hist(data.median_house_value, bins = 500, alpha = 0.5, label = 'median_house_value')

plt.hist(data.median_income, bins = 500, alpha = 0.5, label = 'median_income')

plt.legend(loc='upper left')

plt.show()
```



- 3. Παλινδρόμηση Δεδομένων:
 - a. Προετοιμασία και διαχωρισμός δεδομένων (για Least Mean Squares και Least Squares)
 - i. K-Fold Cross Validation

- b. Least Mean Squares Αλγόριθμος Γραμμικής Παλινδρόμησης:
 - i. Εκπαίδευση (Train) με Gradient Descent και συνάρτηση απώλειας Mean Squared Error.

```
1 # Gradient descent with MSE minimization
def gradient_descent(x, y, epochs = 1000, learning_rate = 0.00006,
                      stopping_threshold = 1e-6):
5
      # Initializing weight, bias, learning rate and iterations
      current_weights = np.ones(len(x[0]))
6
      current_bias = 0.01
8
      epochs = epochs
9
      learning_rate = learning_rate
10
      n = float(len(x))
11
12
      costs = []
13
      previous_cost = None
14
      # Estimation of optimal parameters
15
      for i in range(epochs):
16 🖯
17
          # Making predictions
18
19
          y_predicted = np.dot(x, current_weights) + current_bias
20
          # Calculation the current cost
21
22
          current_cost = mean_squared_error(y, y_predicted)
23
24
          # If the change in cost is less than or equal to
25
          # stopping_threshold we stop the gradient descent
26
          if previous_cost and abs(previous_cost-current_cost)<=stopping_threshold:</pre>
27
28
29
          previous_cost = current_cost
30
31
          costs.append(current_cost)
32
33
          # Calculating the gradients
           weight_derivative = -(2/n) * np.dot(x.T,(y-y_predicted))
34
           bias_derivative = -(2/n) * sum(y-y_predicted)
35
36
37
          # Updating weights and bias
38
           current_weights = current_weights - (learning_rate * weight_derivative)
          current_bias = current_bias - (learning_rate * bias_derivative)
39
40
          # Printing the parameters for each Epoch
41
           print('\n----\n')
42
           print('Epoch:', i+1, '\n\nMSE Cost:', current_cost, '\nMAE Cost:', mean_absolute_error(y,
43
           y_predicted), '\nWeights:\n', current_weights, '\nBias:', current_bias)
44
45 certurn current_weights, current_bias, costs
```

.....

Epoch: 1

MSE Cost: 6773.161026707132 MAE Cost: 82.29455364968523

Weights:

[-0.17827258 1.34917855 1.00529871 1.00066246 1.00082664 1.00039892 1.00081518 1.00230198 1.00481644 1.00310121 1.0000027 1.00053714

1.00141786]

Bias: 0.019875346437962238

.....

Epoch: 2

MSE Cost: 5002.0922248690185 MAE Cost: 70.65578160611246

Weights:

[0.83403302 1.0485425 1.00074646 1.00009303 1.00011676 1.00005675 1.00011538 1.00033319 1.00077154 1.00034256 1.00000052 1.00005457

1.00022746]

Bias: 0.011396652645228773

Epoch: 3

MSE Cost: 3694.364849691922 MAE Cost: 60.77321327020683

Weights:

1.00127832]


Bias: 0.018689438237653587


ii. Δοκιμή (Test), και προβολή αποτελεσμάτων

```
1 -#
 2 # LMS Testing
 4 Y_pred = X_test.dot(estimated_weights.T) + estimated_bias
 6 #
 7 print('\n', 'LMS Testing MSE (with', ep, 'training Epochs):', mean_squared_error(Y_test, Y_pred))
 8 print('\n', 'LMS Testing MAE (with', ep, 'training Epochs):', mean_absolute_error(Y_test, Y_pred))
10 # True vs Predicted Plot
11 plt.figure()
12 plt.scatter(list(range(len(Y_pred))), pd.DataFrame(Y_pred), label='Predicted', color='red')
plt.scatter(list(range(len(Y_pred))), pd.DataFrame(Y_test), label='True')
14 plt.ylabel('median house values')
plt.title('True vs Predicted')
16 plt.legend(loc='best')
17 plt.show()
18
19 # Cost plot
20 costs = pd.DataFrame(costs)
plt.figure(figsize=(20, 5))
22 plt.plot(costs)
23 plt.autoscale()
24 plt.title('Training Costs Plot')
25 plt.ylabel('Training Cost')
26 plt.xlabel('Epochs')
27 plt.show()
```

LMS Testing MSE (with 500 training Epochs): 4.420479071378372

LMS Testing MAE (with 500 training Epochs): 1.9724113151838392





c. Least Squares Αλγόριθμος Γραμμικής Παλινδρόμησης: i. Υλοποίηση Αλγορίθμου

```
2 # 2) LS Building the model
3 🗎#
4 m = []
5 \quad X_{mean} = []
6 Y_mean = np.mean(Y_train)
8 ofor i in range(len(X_train[0])):
      X_mean.append(np.mean(X_train[i]))
     num = 0
10
     den = 0
11
12 = for j in range(len(X_train)):
          num += (X_train[j, i] - X_mean[i])*(Y_train[j] - Y_mean)
13
          den += (X_train[j, i] - X_mean[i])**2
15 m.append(num / den)
17 c = Y_mean - np.dot(np.array(m), np.array(X_mean))
```

ii. Δοκιμή (Test), και προβολή αποτελεσμάτων


```
# LS Testing
# LS_predicted = np.dot(np.array(m), X_test.T) + c

print('\n', 'LS Testing MSE:', mean_squared_error(Y_test, LS_predicted))
print('\n', 'LS Testing MAE:', mean_absolute_error(Y_test, LS_predicted))

# True vs Predicted Plot
plt.figure(figsize=(20, 5))
plt.scatter(list(range(len(LS_predicted))), pd.DataFrame(Y_test), label='True')
plt.plot(pd.DataFrame(LS_predicted), label='Predicted', color='red')
plt.ylabel('median house values')
plt.title('True vs Predicted')
plt.legend(loc='best')
plt.show()
```

LS Testing MSE: 0.042155660171509485

LS Testing MAE: 0.16764192465561106



d. Μη-Γραμμική Παλινδρόμηση με πολυστρωματικό Νευρωνικό Δίκτυο:i. Προετοιμασία Δεδομένων

ii. Δημιουργία και Εκπαίδευση (Train) Μοντέλου

```
1 # Create the Model
 2 model = Sequential()
 3 model.add(Dense(128, activation="relu", input_dim=13))
 4 model.add(Dense(32, activation="relu"))
 5 model.add(Dense(8, activation="relu"))
 6\ 	extstyle \# Since the regression is performed, a Dense layer containing a single neuron with a linear
    activation function.
 7 # Typically, ReLu-based activation are used but since it is performed regression, it is needed a
  linear activation.
 8 model.add(Dense(1, activation="linear"))
10 # Compile model: The model is initialized with the Adam optimizer and then it is compiled.
model.compile(loss='mean_absolute_error', optimizer=Adam(lr=1e-3, decay=1e-3 / 200))
13 # Patient early stopping
es = EarlyStopping(monitor='val_loss', mode='min', verbose=1, patience=200)
16 # Fit the model
17 history = model.fit(X_train, Y_train, validation_data=(X_validation, Y_validation), epochs=50,
    batch_size=100, verbose=2, callbacks=[es])
```

iii. Δοκιμή (Test), προβολή αποτελεσμάτων

```
2 # NN Testing
 3
 4
   # Calculate predictions
  NN_predicted = model.predict(X_test)
8 print('\n', 'NN Testing MSE:', mean_squared_error(Y_test, NN_predicted))
9 print('\n', 'NN Testing MAE:', mean_absolute_error(Y_test, NN_predicted))
10
11 # True vs Predicted Plot
plt.figure(figsize=(20, 5))
plt.scatter(list(range(len(NN_predicted))), pd.DataFrame(Y_test), label='True')
14 plt.scatter(list(range(len(NN_predicted))), pd.DataFrame(NN_predicted), label='Predicted',
   color='red')
plt.ylabel('median house values')
plt.title('True vs Predicted')
17 plt.legend(loc='best')
18 plt.show()
```

NN Testing MSE: 185.6908787764589

NN Testing MAE: 0.14050895666509014

